
인공지능 원천데이터 활용 가이드라인

- 상황별 한국어 영어 대화문 원천데이터 -



작성일 2022. 11. 30

1. 데이터 활용 가이드라인 정보

1.1 데이터 정보 요약

인공지능 학습, 모델 개발 등에 활용 가능한 저작권이 해결된 인공지능 원천데이터 100만 문장 구축

사업명	인공지능 원천데이터 나눔 지원사업	
데이터 이름	상황별 대화문 한국어 영어 원천데이터 구축	
활용 분야	- 양질의 원천데이터 공개를 통한 K-데이터 산업 경쟁력 확대 및 인공지능 기반 시장 활성화 - 자연어처리 인공지능기술 고도화, 언어 및 대화의 추론/평가 등 연구자료로 활용	
데이터 요약	- 상황별 대화문 한국어 영어 원천데이터 구성 : 50가지 이상의 상황 분류에 맞는 100만 문장을 데이터 활용할 수 있도록 학습할 수 있는 데이터 구조로 생성하여 구축한 데이터	
데이터 출처	- 솔트룩스이노베이션	
데이터 이력	배포버전	버전 1.0
	개정이력	신규
	작성자/ 배포자	김영택 / ㈜솔트룩스이노베이션

1.2 데이터 포맷

수집된 원시 데이터를 체계적으로 정제하여, 불필요한 데이터를 제거하고 데이터 셋을 구축하는데 필요한 형태로 저장하며 엑셀과 JSON 형식으로 구성

- 원천데이터 엑셀 형식의 데이터는 문장별 정보를 행으로 나열함
- 데이터 형식은 순번과 텍스트 유형으로 구분하여 표기함

목록	구분	언어	대분류	중분류	말뭉치 순번	문장 순번	문장 ID	화자 D	문장 종류	본문
형식	Text	Text	Text	Text	Num	Num	Num	Text	String	Text
예제	원천	한국어 /영어	공항, 거리, 등	만남, 예약, 등	001	0000 01	1, 2, 3 등	A, B, C	질문/ 답변	안녕하세요?

- 학습용 원천데이터는 '필수값 여부' 항목이 'Y'인 경우 학습데이터(JSON)에 필수 값(Value)이 반드시 존재해야 함
- 학습데이터 생성 (json 파일)시 원천데이터의 포맷과 동일한 '수준1,2,3', 동일한 항목 '순서'를 고려하여 생성이 필요함

1.4 데이터 구성

산출물 업로드 시 폴더명 구성을 설명과 예시를 통해 공유하고, 동일한 폴더구조로 산출물 및 파일을 관리하여야 하므로 개별 파일명의 명명 규칙에 따라 작성함

말뭉치 유형 구분	구축년도	언어분류	대분류	중분류	일련번호 (3자리)
CD: Contextual dialog	22	예) KO: 한국어 EN: 영어	AP:공항	01:물품구매 02:기내음식 주문	001

1.5 데이터 통계

1.5.1 데이터 구축 규모

과제명	주요 내용	데이터 구축량	데이터 형식
상황별 한국어 영어 대화문	장소와 상황에 따라 한국어와 영어 대화문을 데이터 구축 지침에 맞게 원천데이터를 구축하고 데이터의 저작권의 해결하여 인공지능 학습을 위하여 제 3자가 활용할 수 있도록 공개하기 위한 데이터 셋 구축	- 장소와 상황을 50가지 이상의 분류하여 다양한 대화 특성에 맞는 여러 가지의 학습을 위한 데이터셋 - 원시 데이터에서 비속어 비방글, 개인정보 등을 제거한 텍스트 100만 문장	- 화자와 질문 답변이 구분된 대화문 텍스트 말뭉치 - 대분류와 중분류에 맞는 파일 분류 - 데이터 형식 : 엑셀, JSON

데이터 종류	포함 내용	제공 방식
원시 데이터	분류 및 데이터 형식 정의가 되지 않은 110만 이상의 문장 데이터	TXT, 엑셀 포맷 파일
원천데이터	데이터 분류 : 50가지 이상 데이터 : 한국어 500,000 문장 영어 500,000 문장	엑셀, JSON 포맷 파일

2. 데이터 활용 가이드

2.1 데이터 구축 개요

- 사업을 통해 구축하는 데이터의 범위는 일상 생활의 상황별 한국어와 영어 대화문을 인공지능 학습용 데이터로 가공하여 인공지능 산업 발전에 필요한 기반사업으로서 활용이 가능
- 체계적이고 효율적인 방법으로 장소와 상황에 맞는 일상 대화문은 원시 말뭉치를 획득하여 인공지능 시스템에서 학습할 수 있도록 원시데이터의 전처리와 정제 과정을 거쳐 기계학습을 할 수 있는 파일 형태로 구축하여 한국어와 영어 자원의 활용도와 가치를 제고하고자 함
 - 대화형 인공지능 전문가 검토를 통한 50개 이상의 주제 또는 상황 선정
 - 대화형 인공지능 기술 활용도를 제고하여 인공지능 기술 전문가 그룹을 통한 주제 범위 선정
 - 21년 일상 대화 말뭉치 사업의 주제 및 키워드 등 분석
 - 수집데이터 구축 지침 등에 대해서 전문가 검토 후 구축 지침 마련
 - 선정된 주제를 대상으로 화자의 대화를 도와줄 다양한 자료 선정
 - 한국저작권위원회와 협의하여 22년도 공모 과제에 주제 및 카테고리 선정 및 산출물 지침서 개정

2.2 데이터 구매와 자체 시스템을 통한 데이터 생성

- 솔트룩스이노베이션의 자체적으로 보유한 데이터셋 또는 관계사인 솔트룩스와 데이터의 메타정보를 포함한 원시 말뭉치를 구매
- 협력사 자체 시스템으로 생성한 저작권과 지적재산권 문제요소 해소된 데이터 구매
- 데이터 수집 시 원시데이터 또는 원천데이터가 기공개되어 활용되고 있는 데이터 경우, 획득 데이터에서 제외
- 텍스트 데이터의 정제 기준과 항목을 정하여 정제 지침으로 마련하여 이에 따라 텍스트 자료 정제

2.3 4단계 Quality Station의 전수검사로 99.9% 고품질 말뭉치 구축

- 타 기관의 구축 지침과 솔트룩스이노베이션의 품질 관리 지침을 만족하는 99.9% 품질 수준을 위한 검증 프로세스
- 말뭉치 구축 사업 경험을 통한 4단계 Quality Station을 통한 전수 검사 진행
- 획득한 원시 말뭉치의 품질 수준이 95% 이상이 되도록 선별함
- 구축된 말뭉치 자료에 대한 메타정보를 포함한 원천 데이터 구축

2.4 수집 데이터의 저작권 이용 허락 계약 체결

- 데이터 원저작자와 저작권 이용 허락 계약을 체결하여야 하며, 원저작자에게 저작권 이용료를 지급된 데이터 수집
- 기존의 인공지능 학습용 데이터로 공개된 데이터와의 중복을 피하기 위하여 2022년 6월 이전 공개된 대화형 말뭉치는 획득 대상에서 제외함
- 구축된 저작물에 대하여 제3자의 저작권, 지재산, 개인정보에 대한 법률적인 소송이 발생할

경우, 수행기관에서 전담팀을 구성하여 대응함

2.5 사업 수행 지표

- 상황별 한국어 영어 대화문 데이터는 원시데이터, 원천데이터, 최종산출물을 구축하며, 원시데이터는 최종 원천데이터의 110% 수준을 획득함을 목표로 함

구분	데이터 정의	다양성	목표 수량	특성
원시 데이터	문장별 메타정보(장소/상황/화자/언어/구축시기/원저작자 등)를 포함한 원시 대화셋	50개 장소와 상황에 따른 분류	· 110,000 대화셋 · 1,100,000 문장 (txt, xlsx 포맷)	비정형화된 한국어 데이터
원천 데이터	메타정보와 대화셋을 구조화한 파일		· 100,000 대화셋 · 1,000,000 문장 (엑셀, Json 포맷)	구조화 및 정형화된 한국어 영어 파일

2.6 용어의 정리


- 원시데이터 : 기계학습을 목적으로 획득 단계에서 수집 또는 생성한 음성, 이미지, 영상, 텍스트 등의 데이터
- 원천데이터 : 원시데이터를 라벨링 공정에 투입하기 위해 필요한 전처리 등 정제 작업을 수행한 데이터로 라벨링데이터가 부여되지 않은 상태의 데이터
- 데이터 획득 : 인공지능의 기계학습에 필요한 데이터를 현실 세계에서 직접 수집 또는 생성하거나, 이미 보유하고 있는 조직이나 시스템 등으로부터 법률적 제약이 없도록 '원시데이터'를 확보하는 활동
- 데이터 정제 : 획득한 원시데이터를 기계학습에 필요한 형식으로 맞추거나 불필요한 중복을 제거하며, 개인정보를 비식별화하여 처리하는 등 일련의 전처리 과정을 통해 '원천데이터'를 확보하는 활동

3.1 구축 절차

3.1.1 구축 절차

○ 데이터 구축 절차

- 데이터 구축 목적 정의, 데이터 획득, 데이터 정제, 데이터 검사에 이르는 일련의 데이터 구축 프로세스를 사전에 정의하고, 각 프로세스에 따르는 이슈 및 검토사항 등을 도출함
- 데이터 구축 프로세스는 구축 단계별 주요 작업에 대해 서술하나, 순서도·표 등을 활용해 구조화하여 구축 관계자 및 작업자들이 쉽게 이해할 수 있도록 함



○ 공정별 데이터 형식

공정	데이터 정의	데이터 형식
데이터 획득	- 대상: 50개 이상의 장소와 상황을 대상으로 실제 환경에서 대화하는 텍스트 데이터 - 환경: 쌍방 화자 및 다 화자의 대화체 등이 포함된 자연스러운 대화 문장 - 화자 정보(쌍방 대화, 다자간 대화, 질문자, 답변자, 역할)	TXT, XLS 파일
전처리 정제	원시 데이터의 각자 다른 구조 또는 형식의 데이터를 통일된 규격에 맞게 항목별 분리 저장함	XLS 파일
데이터 변환	- 파일정보(파일명, 작성일, 카테고리 분류명, 제작일 등) - 원본형태 (화자가 구분된 대화 텍스트 말뭉치) - 학습용 데이터 형태 (장소, 상황, 발화자 정보 관련 메타 정보를 포함하며, 말차례 바뀔과 화자 정보가 포함된 텍스트 데이터셋) - 정제된 한국어 문장과 영어 대응쌍 문장 포함 - 질문 또는 답변 문장을 상황 대화셋으로 순차적 문장 구조 변환	XLS 파일 JSON 파일

2.1.2 데이터 획득

- 상황별 대화체 데이터 구축 시 원시 데이터 수집에서 수집 데이터의 다양성을 확보하기 위하여 장소, 상황, 질문/답변 구조, 쌍방/다자간, 화자정보, 언어 등 카테고리별 최대한 균등한 비율로 데이터 수집 및 가공하고 사업 종료 시점에 해당 구성에 대한 통계를 작성하기 위해 필요함
- 상황별 질의/응답 대화셋은 5 ~ 25개의 대화셋으로 구성하여 장소와 상황에 적절한 대화 내용을 포함하도록 구성하여 수집함

NO	데이터 획득 형태	수집 방식	데이터 형식	수집처	비고
1	기존 데이터 활용	형식이 다른 파일 정형화 수집	TXT, XLS	솔트룩스이노베이션	한글 40만문장 영어 40만문장
2	직접 생산	데이터 수집용 오픈 시스템 활용	XLS	솔트룩스	한글 20만문장 영어 20만문장

항 목	내 용	
데이터 명	상황별 한국어 영어 대화문 텍스트 데이터	
데이터 포맷	*.txt / *.xlsx	
구축 목표	인공지능 학습용 데이터를 일상생활의 상황에 따른 다른 한국어 영어 대화문 데이터를 대량으로 구축하여 학습된 활용 모델에 적합하도록 구축	
원시 데이터	상황별 대화문 50개 이상의 상황에 맞는 텍스트 데이터 저작권 활용과 제3자 제공의 권한 있는 데이터 기존 타 기관에 공개되지 않은 데이터	
획득 데이터	대화 데이터	양자간 또는 다자간 대화 쌍의 텍스트 데이터
	메타 데이터	장소, 상황정보, 화자, 문장 정보, 화자 정보 등
목표 구축 규모	총 1,000,000 문장	
활용 분야	(산업계) AI 상담센터, 데이터 기반 플랫폼/클라우드 서비스, 챗봇, AI 스피커, 개인비서, 스마트홈 (학계/연구계) 언어기반 기초연구자료, 자연어 연구자료, 대대화 추론 및 평가를 위한 모델학습 자료, 국어정책수립 기초자료 등	
데이터 요약	상황별 대화체 데이터 수집을 위하여 특정 상황에 맞는 대화를 학습용 데이터로 구축하여 챗봇과 번역, 일상 대화에서 인공지능 스피커의 대화 추론을 학습할 수 있는 데이터를 제공하기 위하여 다양한 상황과 질의 문답 형태의 텍스트 데이터를 제공하여 인공지능 학습용 데이터로 구축	
데이터 출처	자사(솔트룩스이노베이션) 또는 협력사 등	

3.1.3 데이터 분류

- (분류 기준) 획득한 데이터가 다양한 형식과 분류에 의하여 혼합되어 있으므로 대화셋별로 상황별 대화문 단일 파일에 취합하여 파일을 생성하고, 이에 맞는 구분코드를 통하여 파일의 저장/관리 및 활용 시 파일의 구분 및 선택을 원활히 할 수 있도록 파일명을 생성하여 관리, 또한 파일 분류는 획득 데이터의 메타 정보 또는 분류 담당자의 분석에 의하여 분류되며 최종 검수 시 확인

- 대분류 14종 목록 및 코드

데이터 종류	순번	대분류	코드
원천 데이터 (원천)	1	거리	ST
	2	공항	AR
	3	관공서	GO
	4	관광안내소	TI
	5	관광지	TO
	6	교육시설	ED
	7	호텔	HT
	8	대중교통	TR
	9	병원	HO
	10	상점	SH
	11	식당	FO
	12	체육시설	AT
	13	편의시설	CO
	14	기타	ET

- 중분류 10종 목록 및 코드

데이터 종류	순번	중분류	코드
원천 데이터 (원천)	1	교환 및 환불	001
	2	구매/추천/주문/환전	002
	3	돌발상황	003
	4	만족도 평가	004
	5	방문/도착	005
	6	불평 토론	006
	7	예약 확인/취소	007
	8	위급/도움요청	008
	9	일상대화	009
	10	정보 안내/문의	010

- 언어분류 2종 목록 및 코드

데이터 종류	순번	언어 종류	코드
원천 데이터 (원천)	1	한국어	KO
	2	영어	EN

- 파일명 규칙 : 획득한 데이터의 전처리 및 정제 단계를 진행하기 위하여 장소와 상황에 맞는 내용의 문장들을 분류하고, 분류된 문장을 한 개의 파일에 취합하여 데이터 학습 진행 시

상황에 다른 데이터 학습이 가능하도록 획득 데이터를 분류하여 저장 및 관리함



3.1.4 데이터 정제

- 데이터 정제는 문장 정제와 비식별화 2가지 기준으로 작업을 진행함
- 문장 정제는 일반 대화에서 사용되는 비표준형 및 구어 발음대로 작성된 풍부한 예시와 띄어쓰기 방법은 정제 지침에 명시
- 비식별화 처리는 개인정보는 정제 단계에서 익명 처리 등 비식별화를 통해 개인정보를 알아볼 수 없게 치환 처리

정제기준	설명
문장 분리	- 문장 분리 기술을 활용하여 3줄 요약으로 문장을 분리 - 분리된 문장은 한 줄씩 개행하여 라벨링 작업자의 작업 효율을 증대
문장 구분 오류	오픈소스 문장 분리기(Koala NLP)와 수행기관이 자체 보유한 한국어 어휘사전 기반 문장 분리기를 결합하여 99% 이상 정확도를 갖는 문장 분리 수행
오타자 수정	수행기관이 자체 보유한 한국어 어휘사전 또는 국립국어원에서 제공하는 한국어 맞춤법/문법 검사기를 활용하여 초성-중성-종성 간의 관계를 고려하여 오타자 판단 및 수정
문장 정제	- 입력 텍스트의 길이와 형태의 적합성 고려 - 수집된 원문 데이터 셋에서 문장 분할 - 불필요하거나 의미없는 데이터 제거 및 모호한 원문 데이터 수정 (문장 나누기, 접속사 추가, 사어, 고어 등 교체) - 반복적으로 나타나는 동일한 형태의 데이터 제거
부적절 표현 혐오표현	부적절한 표현의 범위 -부적절한 표현이란 ‘욕설, 혐오 및 차별 표현, 부정적인 평가 표현, 성적 표현’ 등을 이른다. 해당 표현의 경우 시작과 끝 지점에 ‘\$’ 로 표시하고 최종 결과물에 음절 수만큼의 ‘*’ 로 비식별화 한다.

3.1.5 데이터 변환

- 획득한 원시 데이터를 분류와 정제 과정을 거쳐 최종 학습용 원천데이터로 변환하여 최종 산출물을 생산함

유 형	데이터 정의	데이터 형식
원시 데이터	• 대상: 50개 이상의 장소와 상황을 대상으로 실제 환경에서 대화하는 텍스트 데이터 • 환경: 쌍방 화자 및 다 화자의 대화체 등이 포함된 자연스러운 대화 문장 • 발화자 상세정보(쌍방 대화, 다자간 대화, 질문자, 답변자, 역할)	TXT, XLS 파일
정제 데이터	• 원시 데이터의 각자 다른 구조 또는 형식의 데이터를 통일된 규격에 맞게 항목별 분리 저장함	XLS 파일
원천데이터	• 원본형태 (화자가 구분된 대화 텍스트 말뭉치) • 학습용 데이터 형태 (장소, 상황, 발화자 정보 관련 메타 정보를 포함하며, 말차례 바뀔과 음성 동기화 정보가 포함된 텍스트 데이터셋) • 정제된 한국어 문장과 영어 번역 문장 포함 • 질문 또는 답변 분장을 상황 대화셋으로 순차적 문장 구조 변환	XLS 파일 JSON 파일

- 학습용 원천데이터 구조 : 원천데이터는 학습용 데이터 활용을 위하여 메타정보를 속성명과 타입, 필수요건 작성 예시의 기준을 정하고 이에 맞는 구문으로 데이터를 작성하고 이에 맞는 형식의 Json파일로 생성함



속성	수준 1	수준 2	수준 3	타입	필수값여부	설명
파일정보	id			string	Y	AI 학습데이터 파일 아이디 (수동부여)
	metadata			object		AI 학습데이터 파일 메타 정보
		annotation_level		array(string)	Y	분석 층위: 원천
		title		string	Y	파일명
		year		string	Y	구축년도: 2022
		category 1		string	Y	대분류 : 공항
		category 2		string	Y	중분류: 항공권 예약
		language		string	Y	언어 종류
	utterance			array(object)		발화 정보
		corpus id		num	Y	말뭉치 순번
		speaker_id		string	Y	화자 아이디
		note		string		기타 메모
		corpus		array(object)		문장 단위 정보
			id	num	Y	문장 순번
			Sentence types	string	Y	문장 종류
			Sentence	string	Y	문장

3.1.6 데이터 검수

검수 구분	상세 내용
단계별 검수	○ 품질 향상을 위한 2단계 실시 ○ 수집 단계 검사, 평가 및 완료 단계 검사 기준으로 검수를 진행
수집 단계 검사	○ 데이터 수집 단계에서 수집 항목별 샘플링 (10%)으로 선정하여 민감한 정보(정치적 견해, 개인정보, 특정 인물 비하, 성적 표현) 회피 등 법/제도 준수 항목 검증
평가 및 완료 단계 검사	○ 카테고리별로 데이터량이 편향되지 않도록 데이터량 조정 ○ 품질 검증 정의에서 확정된 각 세부 검증 항목에 따른 검증 수행을 통해 구축 데이터 및 공정의 품질 지표를 측정하는 프로세스이며 검증 결과에 대한 평가를 통해 검증 목표 기준에 대한 재검증을 수행

4.1 데이터 구조 샘플


4.1.1 데이터(파일 구조)



4.1.2 샘플 데이터(엑셀)

	A	B	C	D	E	F	G	H	I	J	K	L
1	FILE_NAME	ANNOTATION_LEVEL	YEAR	CATEGORY1	CATEGORY2	LANGUAGE	UTTERANCE_ID	SPEAKER_ID	NOTE	CORPUS_ID	SENTENCE_TYPES	SENTENCE
2	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	A		1	질문	I want see if it is possible to change the date of my flight.
3	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	B		2	질문	Let me see what I can do for you. Can I see the confirmation email?
4	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	A		3	답변	Here you go. I would like to change it to the following day.
5	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	B		4	답변	Lucky for you there is still available seats on that flight.
6	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	A		5	질문	Perfect, is it a direct flight?
7	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	B		6	답변	Yes, the plane flies directly to St. Petersburg.
8	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	A		7	답변	What charge is there for switching times?
9	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	B		8	답변	We have a surcharge of 30 Euros for changing your reservation.
10	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	A		9	질문	That isn't too steep, when does boarding begin?
11	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0001	B		10	답변	The flight starts boarding at 7 PM but you should arrive at least an hour e
12	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	A		1	답변	Good morning, I am wondering if it's possible to reschedule my flight.
13	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	B		2	답변	Let me check for you. Please, give me your ticket number.
14	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	A		3	답변	My ticket number is EZ12345.
15	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	B		4	질문	Your ticket is a round trip flight from Seoul, South Korea, to Hong Kong. Is
16	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	A		5	답변	Yes. I am scheduled to return to Seoul this Friday but want to stay an extr
17	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	B		6	답변	Your ticket does allow for change of return flight. Let me check if there ar
18	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	A		7	질문	Is there a penalty or any sort of fee if I change my ticket.
19	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	B		8	답변	No, any change is free of charge.
20	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	A		9	답변	Wonderful, I would like to make the change then.
21	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0002	B		10	답변	Your ticket has been updated and I will send an updated itinerary to your
22	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	A		1	답변	I was wondering why I was charged 100 USD.
23	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	B		2	질문	May I see the receipt by chance?
24	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	A		3	질문	Here it is. Do you see 100 USD charged at the bottom?
25	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	B		4	답변	I see. It says, change fee was applied.
26	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	A		5	답변	But my class was E class and heard could change many time I want.
27	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	B		6	답변	This was E class for one year open ticket, you are right.
28	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	A		7	질문	Didn't I have to pay for changing schedule, did I?
29	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	B		8	답변	Let me see how we can return this wrong charge.
30	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	A		9	답변	Thank you so much. 100 USD is big money.
31	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0003	B		10	답변	I know. I will do my best for you, promise.
32	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0004	A		1	답변	Hello, I'd like to change my flight reservation.
33	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0004	B		2	질문	May I have your name and flight number?
34	원천CD2022ENAR01	원천	2022	공항	교환 및 환불	EN	0004	A		3	답변	My name is Jane Smith, and the flight number 876.

4.1.2 샘플 데이터(Json)



```
1 {
2   "data": [
3     {
4       "FILE_NAME": "원천CD2022ENAR01",
5       "ANNOTATION_LEVEL": "원천",
6       "YEAR": "2022",
7       "CATEGORY1": "공통",
8       "CATEGORY2": "고객 및 판매",
9       "LANGUAGE": "EN",
10      "UTTERANCE_ID": "0001",
11      "SPEAKER_ID": "A",
12      "CORPUS_ID": 1,
13      "SENTENCE_TYPES": "질문",
14      "SENTENCE": "I want see if it is possible to change the date of my flight."
15    },
16    {
17      "FILE_NAME": "원천CD2022ENAR01",
18      "ANNOTATION_LEVEL": "원천",
19      "YEAR": "2022",
20      "CATEGORY1": "공통",
21      "CATEGORY2": "고객 및 판매",
22      "LANGUAGE": "EN",
23      "UTTERANCE_ID": "0001",
24      "SPEAKER_ID": "B",
25      "CORPUS_ID": 2,
26      "SENTENCE_TYPES": "질문",
27      "SENTENCE": "Let me see what I can do for you. | Can I see the confirmation email?"
28    },
29    {
30      "FILE_NAME": "원천CD2022ENAR01",
31      "ANNOTATION_LEVEL": "원천",
32      "YEAR": "2022",
33      "CATEGORY1": "공통",
34      "CATEGORY2": "고객 및 판매",
35      "LANGUAGE": "EN",
36      "UTTERANCE_ID": "0001",
37      "SPEAKER_ID": "A",
38      "CORPUS_ID": 3,
39      "SENTENCE_TYPES": "답변",
40      "SENTENCE": "Here you go. | I would like to change it to the following day."
41    },
42    {
43      "FILE_NAME": "원천CD2022ENAR01",
44      "ANNOTATION_LEVEL": "원천",
45      "YEAR": "2022",
46      "CATEGORY1": "공통",
47      "CATEGORY2": "고객 및 판매",
48      "LANGUAGE": "EN",
49      "UTTERANCE_ID": "0001",
50      "SPEAKER_ID": "B",
51      "CORPUS_ID": 4,
52      "SENTENCE_TYPES": "답변",
53      "SENTENCE": "Lucky for you there is still available seats on that flight."
54    }
55  ]
56 }
```